Referencias Bibliográficas y Metodológicas

Modelado Georreferenciado y Fenológico para la Estimación del Rendimiento de Cebada en el Altiplano Central — Reto AgroCebada 2026

El presente documento recopilita el marco bibliográfico, las referencias formales de la literatura especializada, las fuentes de datos geoespaciales y el software estructurado para el desarrollo del modelo predictivo y la plataforma de análisis del Reto AgroCebada 2026.

1. Literatura Fundamental y Ecosistema de Machine Learning

1. **Lang, M., Binder, M., Richter, J., Schratz, P., Pfisterer, F., Coors, S., Au, Q., Casalicchio, G., Kotthoff, L., & Bischl, B. (2019).** *mlr3: A modern object-oriented machine learning framework in R.* Journal of Open Source Software, 4(44), 1903.
   Nota de uso: Marco computacional orientado a objetos utilizado para la construcción, ajuste y validación cruzada de las arquitecturas de aprendizaje automático (*Random Forest*, *XGBoost* y *Elastic Net*).

2. **Pebesma, E., & Bivand, R. (2023).** *Spatial Data Science: With Applications in R.* Chapman and Hall/CRC.
   Nota de uso: Obra de referencia metodológica empleada para el diseño de las operaciones espaciales, la manipulación de mallas ráster y polígonos vectoriales en el lenguaje *R* (utilizando las librerías `sf` y `terra`).

3. **Breiman, L. (2001).** *Random Forests.* Machine Learning, 45(1), 5-32.
   Nota de uso: Fundamento estadístico del algoritmo principal de ensamblaje (*ranger*) seleccionado para optimizar la capacidad de interpolación espacial del rendimiento.

2. Insumos Bioambientales y Cita de Autoría (UNAM)

1. **Cuervo-Robayo, A. P., Téllez-Valdés, O., Gómez, M. A. D., Martínez-Meyer, E., Sánchez-Cordero, V., & Velasco, J. (2020).** *An update of high-resolution monthly climate surfaces for Mexico.* International Journal of Climatology, 40(4), 2232-2246.
   Contexto y justificación metodológica: Durante las etapas iniciales de la investigación, se evaluaron e integraron las bases de datos de variables bioambientales de alta resolución desarrolladas por la **Dra. Ángela Patricia Cuervo Robayo** y su equipo de investigación del Instituto de Biología de la Universidad Nacional Autónoma de México (**UNAM**). No obstante, tras el análisis de ganancia de información y

validación en el pipeline de *mlr3*, estas variables macroclimáticas estáticas se excluyeron deliberadamente del modelo final, debido a que la varianza explicativa del rendimiento a microescala parcelaria dependía de manera crítica de la ingeniería fenológica dinámica (*EVI*, *LOESS*) y no de los gradientes climáticos generales.

3. Software, Paquetes de R y Fuentes Satelitales

1. **Lenguaje de Programación R (Versión 4.3+):** Núcleo analítico para la limpieza de datos, extracción espacial y modelado predictivo.
2. **Constelación PlanetScope / PRO (Planet Labs):** Proveedor de imágenes satelitales multiespectrales de alta resolución ($\sim$3 metros) para la construcción de series temporales del Índice de Vegetación Mejorado (*EVI*).
3. **Google Earth Engine (GEE):** Plataforma en la nube empleada para el filtrado de nubosidad ($< 20\,\%$) y la extracción automatizada de métricas espectrales por polígono ejidal.
4. **Ecosistema de Paquetes en R:**
   - `sf` y `terra`: Manipulación y procesamiento vectorial y ráster de datos geográficos.
   - `tidyverse` (`dplyr`, `ggplot2`): Limpieza, transformación tabular y visualización gráfica de resultados.
   - `mlr3`, `mlr3learners`, `mlr3tuning`: Orquestación del pipeline de aprendizaje automático y validación cruzada anidada.
   - `ranger`: Implementación altamente optimizada del algoritmo de *Random Forest*.
5. **Infraestructura de Aplicación Web y Asistente de IA:** Desarrollo colaborativo de la interfaz gráfica de usuario (*dashboards* geoespaciales) e integración del modelo conversacional basado en Inteligencia Artificial para la consulta de riesgos y proyecciones de rendimiento.