Modelado Georreferenciado y Fenológico para la Estimación del Rendimiento de Cebada en el Altiplano Central

Informe Técnico y Metodológico — Reto AgroCebada 2026

1. Introducción

El cultivo de cebada en el Altiplano Central de México —región que abarca principalmente los estados de Hidalgo, Tlaxcala y Puebla— constituye un pilar socioeconómico estratégico para la agricultura de temporal. Esta zona aporta la mayor parte de la producción nacional orientada a la industria maltera y cervecera, generando empleo de subsistencia e ingresos directos para miles de pequeños y medianos productores. Sin embargo, la rentabilidad y estabilidad del sector enfrentan vulnerabilidades crecientes debido a la variabilidad climática, la degradación del suelo y las limitaciones técnicas en la estimación oportuna de las cosechas.

La agronomía satelital se ha posicionado como una herramienta fundamental para el monitoreo de cultivos a gran escala. No obstante, su implementación práctica en el Altiplano Central enfrenta desafíos técnicos severos. En primer lugar, la persistente nubosidad durante el ciclo primavera-verano interrumpe las series de tiempo ópticas, generando vacíos de información en etapas críticas del desarrollo vegetativo. En segundo lugar, la resolución espacial de los sensores abiertos a menudo resulta en un filtrado incompleto de bordes y caminos en parcelas minifundistas. Finalmente, existe un marcado ruido fenológico provocado por la heterogeneidad de las fechas de siembra y el manejo agronómico diferenciado entre productores.

A esta complejidad se suman los abruptos cambios topográficos y microclimáticos del Altiplano, situados a altitudes que superan los 2,200 metros sobre el nivel del mar. La marcada variabilidad térmica entre el día y la noche, sumada a la distribución irregular de la precipitación, genera gradientes de productividad significativos incluso entre parcelas contiguas. Frente a estas condiciones, surge la necesidad imperiosa de implementar modelos de ciencia de datos capaces de integrar variables bioclimáticas, geomorfológicas y espectrales de alta resolución para estimar con precisión el rendimiento agrícola y mitigar el riesgo sistémico de la región.

2. Justificación

La viabilidad comercial e institucional de las soluciones de agronomía digital radica en su escalabilidad operativa y objetividad. Los métodos tradicionales de evaluación agrícola basados en muestreos de campo e inspecciones manuales resultan lentos, costosos y propensos a sesgos subjetivos que dificultan la toma de decisiones a gran escala.

El presente modelo responde a esta necesidad mediante la integración autómata de fuentes de datos satelitales (PlanetScope/PRO, ERA5-Land, CHIRPS y SoilGrids). Al eliminar la dependencia de la infraestructura física en terreno, la arquitectura propuesta ofrece una cobertura continua, estandarizada y auditable.

Para el sector financiero, esta metodología transforma la gestión del crédito agrícola y los seguros agropecuarios. Al proveer certidumbre analítica sobre la capacidad productiva de cada unidad de superficie, las instituciones financieras pueden evaluar el riesgo crediticio con criterios técnicos rigurosos, reduciendo la asimetría de información y expandiendo la inclusión financiera en comunidades rurales históricamente desatendidas.

3. Objetivos

Objetivo General:
Desarrollar e implementar un modelo de Aprendizaje Automático geoespacial para la estimación del rendimiento de cebada en el Altiplano Central de México, basando su precisión en una rigurosa ingeniería de características que extrae métricas fenológicas avanzadas a partir de sensores remotos de alta resolución.

Objetivos Específicos:

- Extraer y suavizar las series temporales del índice de vegetación EVI provenientes de PlanetScope/PRO mediante regresión LOESS, identificando los hitos fenológicos clave (SOS, POS, EOS) a nivel de parcela.
- Estructurar un conjunto de covariables climáticas y edafológicas continuas para establecer las restricciones físicas del entorno.
- Derivar características predictoras avanzadas (Vigor de emergencia, Tasa de senescencia, Heterogeneidad espacial, PPN) que funjan como proxies directos de la capacidad productiva del cultivo.
- Optimizar arquitecturas de Aprendizaje Automático mediante la infraestructura mlr3, comparando esquemas de validación cruzada para maximizar la capacidad de interpolación espacial.

4. Metodología

La aportación más robusta del presente proyecto radica en la profunda Ingeniería de Características (Feature Engineering) desarrollada para capturar la realidad biológica de las parcelas frente a sus estresores ambientales.

4.1. Fuente de Datos y Covariables Ambientales

Para contextualizar las limitantes físicas del cultivo, se integró un bloque de covariables estructurales y climáticas. Se extrajeron variables edafológicas continuas (porcentajes de limo y arcilla a distintas profundidades a través de SoilGrids) y características topográficas de fricción (elevación y pendiente). Adicionalmente, se construyeron perfiles termodinámicos dinámicos acumulados (temperatura media, temperaturas máximas absolutas, radiación solar entrante y precipitación acumulada) a partir de reanálisis meteorológicos de ERA5-Land y CHIRPS.

Se descargo de diferentes portales del gobierno archivos raster y shapefiles que contuvieran informacion de reelevancia para los cultivos, tales como tipo de suelo, nodos de red urbana, cuencas de agua, etc.

Se extrajeron los datos correspondientes y se analiaron para determinar cuales tendrian influencia en el rendimiento de los cultivos.

En el anexo, se incluye una lista de todos los archivos conseguidos y analizados (111 elementos) al igual que su disponibilidad en el repositorio de github, y en la aplicacion web desarrollada.

Durante esta fase, se evaluaron variables bioambientales adicionales proporcionadas por la investigación de la Dra. Angela Cuervo (UNAM). Sin embargo, tras un análisis de ganancia de información, se decidió deliberadamente no incluirlas en el modelo final, ya que no aportaban varianza discriminante relevante para esta tarea específica de predicción volumétrica a nivel parcela.

4.2. Procesamiento Espectral y Curvas Fenológicas

Si bien los datos ambientales proporcionan el contexto, el núcleo predictivo requirió un modelado directo del fenotipo. Se utilizaron series de tiempo de imágenes de la constelación **Planet (PlanetScope/PRO)** ($\sim$3 metros de resolución). Se seleccionó el **EVI (Índice de Vegetación Mejorado)**, el cual no se satura en etapas de alta densidad foliar.

Para transformar las observaciones discretas en una curva fisiológica continua, se aplicó una regresión local **LOESS (Locally Estimated Scatterplot Smoothing)**. Sobre esta curva se extrajeron las fechas clave imponiendo una estricta **restricción agronómica**: se forzó al algoritmo a ignorar "falsos positivos de invierno"(como avena loca) buscando el inicio del ciclo exclusivamente a partir del mes de mayo (DOY > 120). Así se identificaron el inicio de la estación (SOS), el pico de floración (POS), la madurez fisiológica (EOS) y la duración en días (LOS) de cada parcela.

4.3. Ingeniería de Variables Derivadas

A partir de la parametrización de la curva, se generaron las variables de mayor impacto agronómico del modelo:

- **evi_integral (Productividad Primaria Neta):** Área bajo la curva del EVI. Predictor principal de biomasa total acumulada calculada a partir del dia detectado como inicio.
- **vigor_emergencia_msavi:** Promedio del índice MSAVI durante los primeros 25 días. Evalúa la calidad de establecimiento del stand poblacional.
- **tasa_senescencia:** Pendiente de caída del EVI desde el pico máximo. Indica "secado arrebatado.º estrés hídrico terminal.

4.4. Pipeline de Modelado y Validación

La arquitectura se construyó en R utilizando el framework **mlr3**. Se compararon las familias algorítmicas Random Forest (*ranger*), XGBoost y Elastic Net. Se implementaron validaciones cruzadas tanto de partición espacial estricta (*spcv_coords*) como aleatoria. Se observó que las condiciones macro-regionales limitan la extrapolación lejana; por ende, dado que el objetivo exige predecir en parcelas intercaladas con las de entrenamiento, se

seleccionó el esquema de validación no espacial (aleatorio) para optimizar explícitamente la capacidad de **interpolación**.

5. Resultados y Discusión

El modelo de Random Forest se consolidó como el algoritmo superior para la interpolación espacial, alcanzando un **Error Cuadrático Medio Raíz (RMSE) de ∼0.54 t/ha** y un **Coeficiente de Determinación (R^2) de ∼0.52**.

El análisis de importancia de variables confirmó la coherencia física del modelo. La pertenencia a clusters geográficos dominó el peso predictivo, demostrando que la macroregión dicta el rendimiento base. A nivel de parcela, las variables derivadas de la ingeniería fenológica propia probaron su jerarquía: la radiación acumulada, la duración del ciclo (*duracion_dias*) y la integral de biomasa (*evi_integral*) superaron a la precipitación acumulada. Esto constata que, bajo el régimen del Altiplano analizado, la capacidad estructural del cultivo para interceptar luz sostenidamente, evitando la senescencia prematura por altas temperaturas, fue el factor más determinante para la cosecha.

6. Uso de la Ciencia de Datos en la Inclusión Financiera del Sector Agro

Para llevar esta inteligencia de datos a la operatividad comercial, el resultado final de este proyecto integró el despliegue de una aplicación web interactiva. Esta plataforma no solo centraliza y visualiza geográficamente las predicciones y diagnósticos parcelarios a través de *capas geoespaciales* analíticas, sino que ademas, incorpora un asistente virtual basado en Inteligencia Artificial. Este entorno permitira a los usuarios —desde analistas de crédito hasta gestores de aseguradoras— interactuar fluidamente con los datos, interpretar las variables de riesgo y tomar decisiones estratégicas fundamentadas sin necesidad de manipular código o bases de datos crudas.

7. Conclusiones

La metodología ejecutada en el Reto AgroCebada 2026 corrobora que la solidez de un modelo de estimación agrícola no reside únicamente en la elección del algoritmo final, sino en la rigurosidad analítica de la ingeniería de características.

Si bien la integración de variables abióticas de clima (ERA5, CHIRPS) y suelo (SoilGrids) fue fundamental para definir las fronteras físicas de cada parcela, el pilar predictivo se consolidó al abstraer la biología del cultivo. El uso de imágenes de alta revisita y resolución (PlanetScope), el filtrado algorítmico de malezas invernales (DOY > 120) y el suavizado matemático de la curva fenológica (LOESS) posibilitaron la creación de descriptores de vigor sumamente correlacionados con el rendimiento final.

El contraste de esquemas de validación mediante *mlr3* justificó la configuración de un modelo Random Forest orientado matemáticamente hacia la interpolación, demostrando su utilidad operativa en la geografía de estudio. Finalmente, al materializar esta capacidad predictiva en una plataforma web interactiva dotada de un asistente de Inteligencia Artificial, el proyecto trasciende el ámbito académico para ofrecer una herramienta tecnológica integral, funcional y lista para impulsar el uso de la inteligencia artificial en el sector agrónomopara la toma de desiciones.